


# 連続最適化(1): 制約なし最適化

佐藤一誠

[sato@k.u-tokyo.ac.jp](mailto:sato@k.u-tokyo.ac.jp)

<http://www.ms.k.u-tokyo.ac.jp>

- 田村，村松：最適化法，共立出版，2002



# 最適化問題と最適化アルゴリズム<sup>3</sup>

## ■ 最適化問題(optimization problem):

- $\mathcal{X} \subset \mathbb{R}^d$  上に定義される関数  
 $f : \mathcal{X} \rightarrow \mathbb{R}$  の最小値を求めよ

$$\min_{x \in \mathcal{X}} f(x) \quad x = (x^{(1)}, \dots, x^{(d)})^\top$$

## ■ 最適化アルゴリズム(optimization algorithm):

- 収束する点列の生成アルゴリズム
- 最適性条件: 最適化問題の最適解であるための必要条件

# 制約なし最適化問題

## ■ 制約なし最適化問題(unconstrained optimization problem):

- $\mathcal{X} \subset \mathbb{R}^d$  上に定義される関数  
 $f : \mathcal{X} \rightarrow \mathbb{R}$  の最小値を求めよ

$$\min_{\mathbf{x} \in \mathcal{X}} f(\mathbf{x}) \quad \mathbf{x} = (x^{(1)}, \dots, x^{(d)})^\top$$

- $f$  を目的関数(objective function)とよぶ
- 目的関数は微分可能(differentiable)と仮定する
- 最適性条件:  $\mathbf{x}^*$  が最適解のとき

$$\nabla f(\mathbf{x}^*) = \mathbf{0} \quad [\nabla f(\mathbf{x})]_j = \frac{\partial f}{\partial x^{(j)}}$$

# 講義の流れ




1. 凸最適化問題
2. 最急降下法
3. ニュートン法
4. 準ニュートン法

# 凸関数

- 任意の  $x, x' \in \mathcal{X}$ , 任意の  $\theta \in [0, 1]$  に対して
- $$f((1 - \theta)x + \theta x') \leq (1 - \theta)f(x) + \theta f(x')$$

ならば,  $f$  を凸関数(convex function)とよぶ



# 凸関数

7

$$f((1 - \theta)x + \theta x') \leq (1 - \theta)f(x) + \theta f(x')$$


■  $f$ が一階微分可能のとき,  $f$ が凸関数となるための必要十分条件は

$$\forall x, x' \in \mathcal{X}, \quad f(x') \geq f(x) + \nabla f(x)^\top (x' - x)$$

- 接線が常に関数の下にくる

$$[\nabla f(x)]_j = \frac{\partial f(x)}{\partial x^{(j)}}$$

$$x = (x^{(1)}, \dots, x^{(d)})^\top$$



# 凸関数

$$f((1 - \theta)x + \theta x') \leq (1 - \theta)f(x) + \theta f(x')$$

- 行列が半正定値(positive semi-definite)  
 $\Leftrightarrow$  固有値(eigenvalue)が全て非負
- $f$ が二階微分可能のとき,  $f$ が凸関数となるための必要十分条件はヘッセ行列(Hessian matrix)  $\nabla^2 f(x)$  が半正定値:

$$\forall x \in \mathcal{X}, \quad \nabla^2 f(x) \geq O$$

$$x = (x^{(1)}, \dots, x^{(d)})^\top$$

$$[\nabla^2 f(x)]_{j,j'} = \frac{\partial^2 f(x)}{\partial x^{(j)} \partial x^{(j')}}$$



## ■ 以下の関数の凸性を示せ

1.  $f(x) = x^2, x \in \mathbb{R}$

$f'(x)=2x, f''(x)=2 > 0$

2.  $f(x) = e^x, x \in \mathbb{R}$

$f''(x) = e^x > 0$

3.  $f(x) = -\log x, x > 0$

$f''(x) = 1/x^2$

4.  $f(x) = x \log x, x > 0$

$f''(x) = 1/x$

## ■ 二階微分を求める

1.  $(x^2)'' = (2x)' = 2 > 0$


2.  $(e^x)'' = (e^x)' = e^x > 0$

3.  $(-\log x)'' = (-x^{-1})' = x^{-2} > 0$


4.  $(x \log x)'' = (\log x + 1)' = x^{-1} > 0$

- 任意の  $x, x' \in \mathcal{X}$  , 任意の  $\theta \in [0, 1]$  に対して,  $(1 - \theta)x + \theta x'$  も  $\mathcal{X}$  に属するとき,  $\mathcal{X}$  を凸集合 (convex set) とよぶ
- $x$  と  $x'$  を結ぶ線分上の全ての点が  $\mathcal{X}$  に属する

凸集合



非凸集合



# 凸最適化問題

$$\min_{x \in \mathcal{X}} f(x)$$

■ 凸最適化問題(convex optimization problem):  
関数  $f$  が凸で集合  $\mathcal{X}$  も凸

- 最適解が一意に定まる:

$$x^* = \operatorname{argmin}_{x \in \mathcal{X}} f(x)$$

- 最適解の必要十分条件:


- ◆ 勾配(gradient)がゼロ

$$\nabla f(x^*) = 0$$

$$[\nabla f(x)]_j = \frac{\partial f}{\partial x^{(j)}}$$

$$x = (x^{(1)}, \dots, x^{(d)})^\top$$

- ◆ 凸でない場合は必要条件



# 講義の流れ



## 1. 凸最適化問題

## 2. 最急降下法

- A) ステップ幅の選択
- B) 収束性
- C) 微分不可能な場合

## 3. ニュートン法

## 4. 準ニュートン法

# 最急降下法

## ■ 最急降下法(steepest descent method):


1. 適当に初期値  $x_0$  を定める.
2.  $k = 0, 1, 2, \dots$  に対して,  
収束するまで以下を繰り返す

$$\boldsymbol{x}_{k+1} = \boldsymbol{x}_k - \varepsilon_k \nabla f(\boldsymbol{x}_k)$$

$\varepsilon_k > 0$  : ステップ幅(step size)

勾配を下るように  
パラメータを更新

## ■ 勾配法(gradient method)ともよぶ



# 最急降下法(続き)


15

## ■ 凸最適化問題の場合:

- 大域的最適解(global optimal solution)が求まる

## ■ 非凸最適化問題の場合:

- 一般に局所最適解(local optimal solution)しか求められない
- 様々な初期値から何度か学習し, 一番小さい値を採用する



# 講義の流れ



## 1. 凸最適化問題

## 2. 最急降下法

### A) ステップ幅の選択

- i. 厳密直線探索
- ii. バックトラック直線探索

### B) 収束性

### C) 微分不可能な場合

## 3. ニュートン法



## 4. 準ニュートン法



# ステップ幅の選択

$$\boldsymbol{x}_{k+1} = \boldsymbol{x}_k - \varepsilon_k \nabla f(\boldsymbol{x}_k)$$

## ■ ステップ幅 $\varepsilon_k$ の選び方が難しい:



- **焼きなまし(annealing)**: 「最初は大きく, 徐々に小さく」.  
しかし, 適切に実装することは容易でない
- **正規化(normalization)**  $\varepsilon_k = \varepsilon'_k / \|\nabla f(\boldsymbol{x}_k)\|$ : 勾配が  
大きいとき安定するが, 勾配が小さいときは不安定

# 講義の流れ



## 1. 凸最適化問題

## 2. 最急降下法

### A) ステップ幅の選択

i. 厳密直線探索

ii. バックトラック直線探索

### B) 収束性

### C) 微分不可能な場合

## 3. ニュートン法

## 4. 準ニュートン法

# 厳密直線探索

$$\boldsymbol{x}_{k+1} = \boldsymbol{x}_k - \varepsilon_k \nabla f(\boldsymbol{x}_k)$$

## ■ 厳密直線探索(exact line search):

- 目的関数の値を最小にするステップ幅を求める

$$\min_{\varepsilon_k > 0} f(\boldsymbol{x}_k - \varepsilon_k \nabla f(\boldsymbol{x}_k))$$

- 一般に、一次元の実線形最小化問題を解く必要があるため、最適なステップ幅の探索に時間がかかる

$$\min_{\varepsilon_k > 0} f(\mathbf{x}_k - \varepsilon_k \nabla f(\mathbf{x}_k))$$

- $f(\mathbf{x}) = \frac{1}{2} \mathbf{x}^\top \mathbf{A} \mathbf{x}$  に対する厳密直線探索の解が  
 $\mathbf{A}$  : 正定値対称行列

$$\varepsilon_k = \frac{\|\nabla f(\mathbf{x}_k)\|^2}{\nabla f(\mathbf{x}_k)^\top \mathbf{A} \nabla f(\mathbf{x}_k)} \quad \nabla f(\mathbf{x}) = \mathbf{A} \mathbf{x}$$

で与えられることを示せ

テキスト

$$\min_{\varepsilon_k > 0} f(\mathbf{x}_k - \varepsilon_k \nabla f(\mathbf{x}_k)) \quad f(\mathbf{x}) = \frac{1}{2} \mathbf{x}^\top \mathbf{A} \mathbf{x}$$

$$\begin{aligned} & f(\mathbf{x}_k - \varepsilon_k \nabla f(\mathbf{x}_k)) \\ &= \frac{1}{2} (\mathbf{x}_k - \varepsilon_k \nabla f(\mathbf{x}_k))^\top \mathbf{A} (\mathbf{x}_k - \varepsilon_k \nabla f(\mathbf{x}_k)) \end{aligned}$$

■ これを  $\varepsilon_k$  に関して微分しゼロとおけば,


$$\varepsilon_k \nabla f(\mathbf{x}_k)^\top \mathbf{A} \nabla f(\mathbf{x}_k) - \nabla f(\mathbf{x}_k)^\top \mathbf{A} \mathbf{x}_k = 0$$

■ これを  $\varepsilon_k$  について解けば


$$\varepsilon_k = \frac{\|\nabla f(\mathbf{x}_k)\|^2}{\nabla f(\mathbf{x}_k)^\top \mathbf{A} \nabla f(\mathbf{x}_k)} \quad \nabla f(\mathbf{x}) = \mathbf{A} \mathbf{x}$$

■  $f$  が単峰関数(unimodal function)の場合は、探索によって最小値を探す

- 二分探索法(binary search): 1対1で分割
- 黄金分割探索(golden section search): 1対 $\varphi$ で分割



$$\varphi = \frac{1 + \sqrt{5}}{2} \approx 1.62$$





Wikipediaより

# 実行例

$$f(x^{(1)}, x^{(2)}) = 10(x^{(1)})^2 + (x^{(2)})^2$$

- 厳密直線探索により反復回数が軽減
- ただし、一般に各反復の計算に時間がかかる



# 講義の流れ



## 1. 凸最適化問題

## 2. 最急降下法

### A) ステップ幅の選択

i. 厳密直線探索

ii. バックトラック直線探索

### B) 収束性

### C) 微分不可能な場合

## 3. ニュートン法

## 4. 準ニュートン法



# 最小値の近似探索


$$\mathbf{x}_{k+1} = \mathbf{x}_k - \varepsilon_k \nabla f(\mathbf{x}_k)$$

■ 最小値の探索を近似的に高速に実行

■  $f$  の真の減少量:

$$g(\varepsilon_k) = f(\mathbf{x}_k - \varepsilon_k \nabla f(\mathbf{x}_k)) - f(\mathbf{x}_k)$$

■ 数学演習:  $f$  の減少量の線形予測値  $\varepsilon_k g'(0)$  を求めよ



$$g(\varepsilon_k) = f(\mathbf{x}_k - \varepsilon_k \nabla f(\mathbf{x}_k)) - f(\mathbf{x}_k)$$

■  $g'(\varepsilon_k) = -\nabla f(\mathbf{x}_k)^\top \nabla f(\mathbf{x}_k - \varepsilon_k \nabla f(\mathbf{x}_k))$

より,

$$g'(0) = -\nabla f(\mathbf{x}_k)^\top \nabla f(\mathbf{x}_k) = -\|\nabla f(\mathbf{x}_k)\|^2$$

従って,


$$\varepsilon_k g'(0) = -\varepsilon_k \|\nabla f(\mathbf{x}_k)\|^2$$

- アルミ木規準(Armijo rule): 目的関数の減少量の線形予測値の $\alpha$  倍の減少を保証  $0 < \alpha < 1$

$$\underbrace{f(\mathbf{x}_k - \varepsilon_k \nabla f(\mathbf{x}_k)) - f(\mathbf{x}_k)}_{f \text{ の真の減少量}} \leq \underbrace{-\alpha \varepsilon_k \|\nabla f(\mathbf{x}_k)\|^2}_{f \text{ の減少量の線形予測値 } -\varepsilon_k \|\nabla f(\mathbf{x}_k)\|^2 \text{ の } \alpha \text{ 倍}}$$

$f$  の真の減少量

$f$  の減少量の線形予測値  
 $-\varepsilon_k \|\nabla f(\mathbf{x}_k)\|^2$  の $\alpha$  倍



# アルミホ規準

$$g(\varepsilon_k) \leq \alpha \varepsilon_k g'(0)$$


- $f(x) = \frac{1}{2} x^\top A x$  のとき,  $\alpha = 1/2$  のアルミホ規準

を満たす最大の  $\varepsilon_k$  は, 最適なステップ幅

$$\frac{x_k^\top A^2 x_k}{x_k^\top A^3 x_k}$$

と一致する

証明は宿題



# バックトラック直線探索

$$\boldsymbol{x}_{k+1} = \boldsymbol{x}_k - \varepsilon_k \nabla f(\boldsymbol{x}_k)$$

## ■ バックトラック直線探索(backtracking line search)

- $\varepsilon_k = 1$  に初期化
- アルミホ規準

$$f(\boldsymbol{x}_k - \varepsilon_k \nabla f(\boldsymbol{x}_k)) - f(\boldsymbol{x}_k) \leq -\alpha \varepsilon_k \|\nabla f(\boldsymbol{x}_k)\|^2$$

が成り立つまで  $\varepsilon_k$  を

$$\varepsilon_k \leftarrow \beta \varepsilon_k$$



と減衰させる

$$0 < \alpha, \beta < 1$$

# 実行例

$$f(x^{(1)}, x^{(2)}) = 10(x^{(1)})^2 + (x^{(2)})^2$$

■ バックトラック直線探索により, 反復回数が軽減



# 講義の流れ



1. 凸最適化問題
2. 最急降下法
  - A) ステップ幅の選択
  - B) 収束性
  - C) 微分不可能な場合
3. ニュートン法
4. 準ニュートン法

- $k$  が十分大きいとき,

$$\|\mathbf{x}_{k+1} - \mathbf{x}^*\| \leq c \|\mathbf{x}_k - \mathbf{x}^*\|$$

$$\mathbf{x}^* = \operatorname{argmin}_{\mathbf{x} \in \mathcal{X}} f(\mathbf{x}) \quad 0 < c < 1$$

- 厳密直線探索を用いた最急降下法は,  
一次収束(linear convergence)する

$$n \text{ 次収束: } \|\mathbf{x}_{k+1} - \mathbf{x}^*\| \leq c \|\mathbf{x}_k - \mathbf{x}^*\|^n$$



# 講義の流れ



## 1. 凸最適化問題

## 2. 最急降下法

- A) ステップ幅の選択
- B) 収束性
- C) 微分不可能な場合

## 3. ニュートン法

## 4. 準ニュートン法

# 微分不可能な 制約なし最適化問題

$$\min_{x \in \mathcal{X}} f(x)$$

- 目的関数  $f$  が微分不可能(non-differentiable)の場合はどうするか？
- 微分概念を一般化した劣微分を用いる

# 劣勾配法


- 凸関数  $f$  の  $x'$  での劣勾配(sub-gradient)とは、全ての  $x \in \mathcal{X}$  に対して次式を満たす  $\xi$  :

$$f(x) \geq f(x') + \xi^\top (x - x')$$

- $f$  が微分可能なとき,  $\xi = \nabla f(x')$
- 上式を満たす  $\xi$  全体を  $\partial f(x')$  で表し劣微分(sub-differential)とよぶ

## 劣勾配法:

- 勾配法において、微分不可能な点では、劣微分のどれかの値を用いる



# 近接勾配法

$$\min_{x \in \mathcal{X}} f(x) + g(x)$$

- $f$  : 凸で微分可能,  $g$  : 凸で微分不可能
- 適当な初期値から  $x$  を次式で更新:

$$x_{k+1} = \operatorname{argmin}_x \underbrace{\nabla f(x_k)^\top (x - x_k)}_{f \text{ の } x_k \text{ 周りの線形近似}} + \underbrace{\frac{1}{2\varepsilon_k} \|x - x_k\|^2}_{\text{近接項}} + g(x)$$

$f$  の  $x_k$  周りの

線形近似

近接項

(線形近似が成り立つよう  
解を  $x_k$  の近傍で探索)

- 近接勾配法 (proximal gradient method) とよぶ

# 講義の流れ



1. 凸最適化問題
2. 最急降下法
3. ニュートン法
4. 準ニュートン法

# 2階微分

- 勾配法では1階微分しか用いていない
- 2階微分も用いると反復回数を減らせるのでは？

$$\boldsymbol{x}^* = \operatorname{argmin}_{\boldsymbol{x} \in \mathcal{X}} f(\boldsymbol{x})$$

- 1階微分: 勾配ベクトル  $\nabla f(\boldsymbol{x})$

$$[\nabla f(\boldsymbol{x})]_j = \frac{\partial f(\boldsymbol{x})}{\partial x^{(j)}} \quad \boldsymbol{x} = (x^{(1)}, \dots, x^{(d)})^\top$$

- 2階微分: ヘッセ行列  $\nabla^2 f(\boldsymbol{x})$

$$[\nabla^2 f(\boldsymbol{x})]_{j,j'} = \frac{\partial^2 f(\boldsymbol{x})}{\partial x^{(j)} \partial x^{(j')}}$$

# 目的関数の二次近似


- 二次のテラー展開(Taylor expansion)を用いて  $f$  を現在の解  $x_k$  の周りで近似する:

$$f(x) \approx f_k(x)$$

$$f_k(x) = f(x_k) + \nabla f(x_k)^\top (x - x_k)$$

$$+ \frac{1}{2} (x - x_k)^\top \nabla^2 f(x_k) (x - x_k)$$

- 二次近似を最小にする点に解を更新する



# 目的関数の二次近似

$$f_k(\boldsymbol{x}) = f(\boldsymbol{x}_k) + \nabla f(\boldsymbol{x}_k)^\top (\boldsymbol{x} - \boldsymbol{x}_k) + \frac{1}{2} (\boldsymbol{x} - \boldsymbol{x}_k)^\top \nabla^2 f(\boldsymbol{x}_k) (\boldsymbol{x} - \boldsymbol{x}_k)$$

- $f_k$  の勾配をゼロと置いた方程式

$$\nabla f_k(\boldsymbol{x}) = \nabla f(\boldsymbol{x}_k) + \nabla^2 f(\boldsymbol{x}_k) (\boldsymbol{x} - \boldsymbol{x}_k) = \mathbf{0}$$

を解けば,  $f_k$  の最小解が得られる:

$$\boldsymbol{x} = \boldsymbol{x}_k - (\nabla^2 f(\boldsymbol{x}_k))^{-1} \nabla f(\boldsymbol{x}_k)$$

- ヘッセ行列が逆を持たないときは, **単位行列の定数倍**を加える(**正則化, regularization**):

$$(\nabla^2 f(\boldsymbol{x}_k) + \mu \mathbf{I})^{-1}, \quad \mu > 0$$



# ニュートン法

## ■ ニュートン法(Newton method):

1. 適当に初期値  $x_0$  を定める.
2.  $k = 0, 1, 2, \dots$  に対して,  
収束するまで以下を繰り返す

$$\boldsymbol{x}_{k+1} = \boldsymbol{x}_k - \varepsilon_k (\nabla^2 f(\boldsymbol{x}_k))^{-1} \nabla f(\boldsymbol{x}_k)$$


$$0 < \varepsilon_k \leq 1 : \text{ステップ幅}$$

- ## ■ $f$ が二次関数とは限らないので, ステップ幅を導入して更新量を調整する

# ニュートン法

- 一般にニュートン法という名称は、方程式の解を求めるアルゴリズムを指す
- 前ページのアルゴリズムでは  $\nabla f(x) = 0$  の解を求めている
- 1次元での直感的解釈:

$$x_{k+1} = x_k - (f''(x_k))^{-1} f'(x_k)$$



- $k$  が十分大きいとき, 最適解  $x^*$  の近傍で  
二次収束(quadratic convergence)する

$$\|x_{k+1} - x^*\| \leq c \|x_k - x^*\|^2$$

$$x^* = \operatorname{argmin}_{x \in \mathcal{X}} f(x) \quad 0 < c < 1$$

- しかし, 逆行列  $\nabla^2 f(x_k)^{-1}$  を求める必要があるため, 各反復の計算に時間がかかる

# 講義の流れ



1. 凸最適化問題
2. 最急降下法
3. ニュートン法
4. 準ニュートン法

- ニュートン法は、収束までの反復数は少なくなくて済むが、各反復でのヘッセ行列の逆

$$\nabla^2 f(\boldsymbol{x}_k)^{-1}$$

の計算に時間がかかる

- 勾配ベクトル  $\nabla f(\boldsymbol{x})$  を用いて近似計算することにする

# 正割条件

- 目的関数  $f(\boldsymbol{x})$  の  $\boldsymbol{x}_k$  周りでの二次近似  $f_k(\boldsymbol{x})$  :

$$f_k(\boldsymbol{x}) = f(\boldsymbol{x}_k) + \nabla f(\boldsymbol{x}_k)^\top (\boldsymbol{x} - \boldsymbol{x}_k) + \frac{1}{2} (\boldsymbol{x} - \boldsymbol{x}_k)^\top \nabla^2 f(\boldsymbol{x}_k) (\boldsymbol{x} - \boldsymbol{x}_k)$$

- その勾配は

$$\nabla f_k(\boldsymbol{x}) = \nabla f(\boldsymbol{x}_k) + \nabla^2 f(\boldsymbol{x}_k) (\boldsymbol{x} - \boldsymbol{x}_k)$$

- $\nabla f(\boldsymbol{x}_{k-1}) = \nabla f_k(\boldsymbol{x}_{k-1})$  のとき,

$$\nabla^2 f(\boldsymbol{x}_k) (\boldsymbol{x}_k - \boldsymbol{x}_{k-1}) = \nabla f(\boldsymbol{x}_k) - \nabla f(\boldsymbol{x}_{k-1})$$

を得る. これを**正割条件(secant condition)**という

- $H_k$  : ヘッセ行列  $\nabla^2 f(x_k)$  の近似
- 準ニュートン法(quasi-Newton method) :  
正割条件

$$H_k(x_k - x_{k-1}) = \nabla f(x_k) - \nabla f(x_{k-1})$$

を満たす  $H_k$  の中で性質の良いものを選ぶ

- 対称
- 正定値
- 逆行列が直接求められる

# BFGSアルゴリズム

## ■ BFGSアルゴリズム(Broyden-Fletcher-Goldfarb-Shanno algorithm):

$$H_{k+1} = H_k + \frac{t_k t_k^\top}{s_k^\top t_k} - \frac{H_k s_k s_k^\top H_k}{s_k^\top H_k s_k}$$

$$s_k = x_{k+1} - x_k \quad t_k = \nabla f(x_{k+1}) - \nabla f(x_k)$$

- $H_{k+1}$  は常に対称
- $H_k$  が正定値かつ  $s_k^\top t_k > 0$  ならば  $H_{k+1}$  も正定値
- 逆行列が直接求められる:

$$H_{k+1}^{-1} = H_k^{-1} + \frac{(s_k^\top t_k + t_k^\top H_k^{-1} t_k) s_k s_k^\top}{(s_k^\top t_k)^2} - \frac{H_k^{-1} t_k s_k^\top + s_k t_k^\top H_k^{-1}}{s_k^\top t_k}$$



# 講義の流れ



1. 凸最適化問題
2. 最急降下法
3. ニュートン法
4. 準ニュートン法

## ■ 凸最適化問題

- 目的関数が凸関数で定義域が凸集合
- 最適解が一意に定まる

## ■ 最急降下法

- 勾配を降下するように値を更新
- ステップ幅の選択が重要
- 目的関数が微分不可能な場合は、劣勾配法や近接勾配法を用いる

## ■ ニュートン法

- 二階微分の情報を利用する
- ヘッセ行列の近似を用いる準ニュートン法が実用的

# 次回の予告



## ■ 制約付き最適化

# 宿題1

52

$$g(\varepsilon_k) \leq \alpha \varepsilon_k g'(0)$$


$$g(\varepsilon_k) = f(\mathbf{x}_k - \varepsilon_k \nabla f(\mathbf{x}_k)) - f(\mathbf{x}_k)$$

■  $f(\mathbf{x}) = \frac{1}{2} \mathbf{x}^\top \mathbf{A} \mathbf{x}$  のとき,  $\alpha = 1/2$  のアルミホ規準

を満たす最大の  $\varepsilon_k$  は, 最適なステップ幅

$$\varepsilon_k = \frac{\mathbf{x}_k^\top \mathbf{A}^2 \mathbf{x}_k}{\mathbf{x}_k^\top \mathbf{A}^3 \mathbf{x}_k}$$

と一致することを示せ



■ 二次関数  $f(x) = \frac{1}{2}x^\top Ax$  に対する

厳密直線探索を用いた最急降下法は、

$$\|x_{k+1} - x^*\|_A \leq c^2 \|x_k - x^*\|_A \quad \|x\|_A = x^\top Ax$$

$$c = \frac{1 - \lambda_{\min}/\lambda_{\max}}{1 + \lambda_{\min}/\lambda_{\max}}$$

$$\lambda_{\max} \geq \lambda_{\min} > 0:$$

$A$  の最大, 最小固有値

を満たすことを示せ

$$x_{k+1} = x_k - \varepsilon_k \nabla f(x_k)$$

$$\nabla f(x) = Ax$$

$$\varepsilon_k = \frac{\|\nabla f(x_k)\|^2}{\nabla f(x_k)^\top A \nabla f(x_k)}$$

■ ヒント: カントロビッチの不等式  
(Kantorovich's inequality)

$$\forall \boldsymbol{x} \neq \mathbf{0}, \quad \frac{4\lambda_{\min}\lambda_{\max}}{(\lambda_{\min} + \lambda_{\max})^2} \leq \frac{\|\boldsymbol{x}\|^4}{\boldsymbol{x}^\top \boldsymbol{A}^{-1} \boldsymbol{x} \cdot \boldsymbol{x}^\top \boldsymbol{A} \boldsymbol{x}}$$


$\lambda_{\max} \geq \lambda_{\min} > 0$ :  
 $\boldsymbol{A}$  の最大, 最小固有値

を用いる

- バックトラック直線探索を用いた勾配法を実装し、以下の関数を最小化せよ:

$$f(x^{(1)}, x^{(2)}) = 10(x^{(1)})^2 + (x^{(2)})^2$$

- 実行例:



■ BFGSアルゴリズムのヘッセ行列の更新式:

$$H_{k+1} = H_k + \frac{t_k t_k^\top}{s_k^\top t_k} - \frac{H_k s_k s_k^\top H_k}{s_k^\top H_k s_k}$$

$$s_k = x_{k+1} - x_k \quad t_k = \nabla f(x_{k+1}) - \nabla f(x_k)$$

A) 逆行列の更新式を求めよ

$$H_{k+1}^{-1} = H_k^{-1} + \frac{(s_k^\top t_k + t_k^\top H_k^{-1} t_k) s_k s_k^\top}{(s_k^\top t_k)^2} - \frac{H_k^{-1} t_k s_k^\top + s_k t_k^\top H_k^{-1}}{s_k^\top t_k}$$

B)  $H_k$  が正定値かつ  $s_k^\top t_k > 0$  のとき,  
 $H_{k+1}$  も正定値であることを示せ



# 宿題4 (ヒント)

57

A) シャーマン・モリソン公式

(Sherman–Morrison formula)を用いる:

$c \neq b^\top A^{-1} b$  のとき  $B = A - \frac{1}{c} b b^\top$  に対して

$$B^{-1} = A^{-1} + \frac{A^{-1} b b^\top A^{-1}}{c - b^\top A^{-1} b}$$

B) 更新式の別表現を用いる:

$$H_{k+1}^{-1} = \left( I - \frac{s_k t_k^\top}{s_k^\top t_k} \right) H_k^{-1} \left( I - \frac{t_k s_k^\top}{s_k^\top t_k} \right) + \frac{s_k s_k^\top}{s_k^\top t_k}$$